



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH



Barcelona
Supercomputing
Center
Centro Nacional de Supercomputación



XAI: eXplainable AI

eXplainable AI

- Conjunt de tècniques, mètodes i metodologies
- **Objectiu:** augmentar l'explicabilitat, transparència i/o interpretabilitat d'un model d'intel·ligència artificial

Definicions (fuzzy):

- ❖ **Transparència:** capacitat d'un model de ser inspeccionat (algorítmica, codi font, conjunt de dades d'entrenament, etc.)
- ❖ **Interpretabilitat:** capacitat d'un model de ser comprès per un usuari sense coneixements tècnics avançats (principalment, quina és la relació entre les entrades i les sortides?)
- ❖ **Explicabilitat:** capacitat de generar explicacions sobre el funcionament d'un model que un humà és capaç d'entendre

Transparència (aprox.)

❖ Transparència alta:

- Regressió, KNN, arbres de decisió, K-Means, Apriori, algoritmes de grafs

❖ Transparència moderada:

- GLMs, EBMs, SVMs (amb kernels no lineals), PCA, DBSCAN

❖ Transparència baixa:

- Xarxes neuronals, Gradient Boosting Machines, ensembles

Per què és important la interpretabilitat?

❖ Sense interpretabilitat...

- Opacitat
- Impossibilitat d' entendre les prediccions fetes
- No es poden anticipar ni analitzar els esbiaixos
- Manca de confiança
- Ho fem tot a les mètriques

Conseqüències ètiques i legals

- ❖ COMPAS (<https://www.propublica.org/article/how-we-analyzed-the-compas-recidivism-algorithm>)
- ❖ EU AI Act article 86: Right to Explanation of Individual Decision-Making (<https://artificialintelligenceact.eu/article/86>)
- ❖ Medicina, justícia, salut, finances, sistemes crítics...

Els limits de l'explicabilitat

- ❖ L'explicabilitat pot servir per aconseguir interpretabilitat
- ❖ *La forma d'una explicació depèn de la seva funció com a resposta a una qüestió, en un marc conversacional (Slugoski et al., 1993)*
- ❖ Màximes de Grice (1975):
 - Manera: *sigues clar*
 - Qualitat: *contribució vertadera*
 - Quantitat: *mesura justa d'informació*
 - Relació: *focus en la rellevància*

LIME: explicacions locals i agnòstiques


❖ Explicacions locals: sobre una predicció concreta

❖ Explicacions agnòstiques al model


- De models molt simples a molt complexos

❖ Pertorbacions de l'entrada: $(x_1, x_2, \dots, x_n) \rightarrow (x'_1, x'_2, \dots, x'_n), (x''_1, x''_2, \dots, x''_n) \dots$

- Ponderació de cada pertorbació, exponencials respecte de l'error
- Noves sortides $y', y'', \dots$
- Regressió lineal (ponderada pels pesos), que ens dóna la **contribució** de cada x_i




LIME: explicacions locals i agnòstiques



<https://www.oreilly.com/content/introduction-to-local-interpretable-model-agnostic-explanations-lime/>

SHAP: explicacions globals i agnòstiques

- ❖ Explicacions locals o globals (sobre un conjunt de prediccions)
- ❖ Explicacions agnòstiques al model
- ❖ Mètode basat en Teoria de Jocs (Teoria de Coalicions)
 - Idea: calcular la **contribució marginal** de cada característica en el valor de la predicció
 - “Posar i treure” característiques per calcular aquesta contribució
 - Treure x_i : substituir x_i pel seu valor esperat, e.g. $|x_i|$



SHAP: explicacions globals i agnòstiques



- ❖ Exemple: *Característiques* = $\{a, b, c\}$
- ❖ Si volem saber la contribució marginal esperada d' a , necessitarem considerar els casos:
 - $v_1 = v(\{a\}) - v(\emptyset)$ (ponderada per 2 seqüències que comencen per a : a, b, c i a, c, b)
 - $v_2 = v(\{b, a\}) - v(\{b\})$ (només 1 seqüència comença per b, a : b, a, c)
 - $v_3 = v(\{c, a\}) - v(\{c\})$ (només 1 seqüència comença per c, a : c, a, b)
 - $v_4 = v(\{b, c, a\}) - v(\{b, c\})$ (hi ha 2 maneres d'ordenar $\{b, c\}$: b, c, a i c, b, a)
- ❖ En total, 6 seqüències possibles. El valor de Shapley serà:

$$\frac{1}{6} \cdot [2 \cdot v_1 + 1 \cdot v_2 + 1 \cdot v_3 + 2 \cdot v_4]$$

pgeon: explicabilitat en agents

- ❖ Explicacions del comportament d'un agent
 - A partir de l'observació
 - Poden ser agents opacs: RL, rule-based, humans
- ❖ Construcció de *policy graphs*
 - $P(a|s), P(s'|s, a)$
 - Explicacions en llenguatge natural
- ❖ Permet analitzar trajectòries esperades
 - Detecció d'intencions

Explaining the Behaviour of Reinforcement Learning Agents in a Multi-Agent Cooperative Environment Using Policy Graphs (2024)
Domenech-i-Vila, M. et al.
<https://www.mdpi.com/2079-9292/13/3/573>



* Why did not you perform X in Y state?

State: D-Co-L-S-S-T-B-L

I would have chosen: Actions.Left

I would choose Top if:


+ D-Co-L-S-S-R-R-T

pot_pos_0 = T -> pot_pos_0 = R

service_pos = B -> service_pos = R

soup_pos = L -> soup_pos = T

pgeon: explicabilitat en agents



Exemple: evolució de les **intencions** (en forma de **probabilitats**)