D4. REPORT

Grau Intel·ligència Artificial - Modelització Estadística

Grup 123

1. Introducció

a. Problema

La diabetes és una malaltia crònica que afecta a milions de persones al voltant del món i que es caracteritza per alteracions en la producció d'insulina. Per tant, per a poder millorar la seva prevenció, diagnòstic i tractament és clau analitzar els diversos factors que determinen el nivell d'aquesta hormona, com és el cas del colesterol. Tot i així, identificar quines d'aquests tenen un impacte significatiu en aquestes medicions i com evolucionen al llarg del temps segueix requerint un estudi força complex.

Aquest projecte es centrarà en analitzar una base de dades de pacients diabètics per explorar com les diverses variables, on s'inclouen tan observacions clíniques com d'estil de vida per a proporcionar una base sòlida de coneixement sobre aquesta enfermetat i d'aquesta manera facilitar futures investigacions sobre el tema.

b. Entrega D2

1. Obtenció de les dades

La nostra base de dades la vam obtenir a partir de la pàgina web Kaggle, on vam trobar diverses opcions amb les que treballar. Finalment, el dataset que vam escollir per al nostre projecte és un relacionat amb casos de diabetes.

La pàgina en qüestió és:

https://www.kaggle.com/datasets/ankitbatra1210/diabetes-dataset?resource=download

Degut a que aquesta base de dades no té cap variable temporal, hem agafat una altra relacionada amb el tema per a poder fer el Time Series. La base en qüestió es troba integrada en R, tot i que en aquest document s'explica com obtenir la:

https://cran.r-project.org/web/packages/fpp/fpp.pdf

Per a descarregar la base principal ho vam fer directament desde la propia pàgina web, ja que no calia fer res més.

Per la base secundària, de les dades disponibles hem agafat el a10, ja que són les dades relacionades amb el nostre projecte.

Aquesta base està integrada en el propi R i per tant no és necessari descarregar la, només carregar la.

La nostra base de dades consisteix en tota una sèrie de dades i informació sobre diferents casos de pacients que pateixen diabetes. Algunes d'aquestes dades són:

- Nivells d'insulina
- Edat
- Nivells de colesterol
- Antecedents familiars

Aquestes dades permeten veure alguns dels factors més rellevants a l'hora de veure els motius per els quals una persona pateix diabetes.

2. Estructura del Dataset

A les següents taules es mostren les característiques del dataset en qüestió abans del preprocessing:

Nombre de files	Nombre de variables	Nombre de variables numériques	Nombre de variables categóriques	Nombre de variables binàries	Nombre de variables temporals	Dades faltants en el 'dataset':
70000	34	13	21	16	1	0

Aquesta base no té cap missing a cap de les columnes, lo que la fa una base de dades molt completa i sólida per a treballar.

3. Pre-processing

Degut a que la base de dades no té cap missing, el treball de preprocessing per a gestionar aquests ens el hem pogut estalviar, facilitant així la preparació de la base de dades.

Per altra banda hem vist que la base tampoc presenta outiliers preocupants, més enllà d'alguns valors atípics però no imposibles en algunes variables com ara el BMI, els nivells de colesterol o els nivells d'insulina.

El que si hem fet amb la base de dades principal ha estat eliminar les variables que considerem més irrellevants per al desenvolupament del treball, amb l'objectiu de simplificar la feina.

Algunes d'aquestes variables han estat les que poden ser massa específiques, si només afecten a una part de la població (com les relacionades amb embarassos), o les que fan referència a pacients que pateixen enfermetats molt específiques, com ara la variables Cystic Fibrosis Diagnosis. També hem eliminat variables que fan referència a factors que no presenten un gran efecte en la diagnosis de la diabetes, com Neurological Assessments, per exemple.

c. D3. Work plan

Gantt diagram

	Septiembre		Octubre					Noviembre				Diciembre			
	13-20	21-27	28-5	6-12	13-19	20-26	27-2	3-9	10-16	17-23	24-30	1-7	8-14	15-18	Final
Trobar el dataset del projecte i adaptarla															
Realitzar la documentació inicial del projecte															
Planificar la divisió de treball															
Fer el pla de contingència de riscos															
Diagrama de Gantt															
Preprocessing final															
Anàlisis i descripció de les variables univariants i bivariants															
Valorar la qualitat d'una variable numèrica amb un MLGz															
Valorar la qualitat d'una variable binaria amb model de regressió															
Realitzar un model de sèrie temporal															
Anàlisi de PCA per variables numeriques															
Clustering jeràrquic i particional															
Perfilació dels clusters															
Argumentació dels resultats															
Divisió de les tasques final															
Diagrama de Gantt final, i conclusió del pla de contingència															
Realització del pdf final de projecte															
Preparar la presentació del projecte															

Division of tasks

Participant	Pablo	Albert	Verónica	Marina
Búsqueda de la base de dades	X	X	X	X
Explicació i estructura inicial de la base	X	**X**	X	
Descripció del preprocessing inicial	X			**X**
Metadata		X	**X**	
Diagrama de Gantt	X	**X**		
Divisió de tasques			X	**X**
Pla de contingència de riscos	**X**			X
Preprocessing final			X	**X**
Descripció i conclusions inicials de les univariants i bivariants	**X**	X	X	
Valorar la qualitat d'una variable numèrica amb un MLGz			**X**	X
Valorar la qualitat d'una variable binaria amb model de regressió	X	**X**		
Model de sèrie temporal	X			**X**
Anàlisi de PCA per variables numeriques	**X**	X		
Clustering jeràrquic i particional		**X**		X
Perfilació dels clusters	**X**		X	
Argumentació i conclusió dels resultats			**X**	X
Divisió de tasques final real		X		**X**
Diagrama de Gantt final real	**X**		X	
Riscos reals que han sigut adreçats i explicació dels canvis fets del pla inicial		X	**X**	

Brief risk contingency plan

Risk	How to prevent	How to manage
Risk1		
Algun membre del grup abandona el grau o es posa malalt i no pot dur a terme les seves tasques	Cada tasca té com a mínim 2 membres assignats	La resta de tasques es reorganitzen en funció del integrants restants
Risk2		
Algun membre no pot assistir a la presentació del projecte	El treball que es fa es posa en comú i en especial els continguts a explicar directament a la presentació	La part a explicar per la persona en qüestió es reparteix entre la resta del grup
Risk3		
Es perd el treball dut a terme a causa d'un error tècnic	Tot el treball dut a terme es puja a la carpeta compartida de Drive	Es comprova que la versió dels documents és la més actualitzada i si no ho és, s'apliquen les modificacions necessàries
Risk4		
Situació excepcional que impedeixi el treball presencial (ex. estat de pandèmia)	El treball ha d'estar pujat i tots els membres han de tenir accés desde casa	Es fan reunions virtuals per a posar en comú el treball i organitzar tasques, així com per a facilitar el treball en grup

d. Objectius

L'objectiu d'aquest projecte és analitzar i descriure estadísticament els nivells d'insulina i colesterol, entre altres variables, respecte una base de dades de pacients diabètics per identificar els factors clínics i d'estil de vida que estan associats significativament amb les variacions en aquests nivells. Per a això hem utilitzat models lineals generalitzats (GLMz), així com un model de regressió lineal de resposta binària, proporcionant una anàlisi detallada dels possibles determinants de les variables objectiu.
A més, s'inclou una anàlisi de sèries temporals dels medicaments relacionats amb la diabetis per identificar tendències i patrons d'ús al llarg del temps. Es durà a terme la validació dels models ajustats per avaluar-ne la capacitat de predicció en les dades dels pacients, amb la finalitat d'establir una base per a futurs estudis relacionats.

Analyses Descriptifs de dades

Adult 2022

Introducció

Aquest document és una guia per a l'anàlisi descriptiva i no un producte de treball. Aquí hi podeu trobar exemples bàsics per a l'anàlisi descriptiva de dades.

Metodologia

Utilitzarem el paquet `dlookr` per a l'anàlisi descriptiva i el paquet `ggplot2` per a la visualització de dades.

Analisis Descriptiu

Visualització i descripció general de dades

El primer pas abans de començar qualsevol anàlisi és familiaritzar-se amb les dades. Per fer-ho, podem utilitzar funcions com `str()`, `summary()` o `head()`. Aquestes funcions ens donen una idea de l'estructura de les dades, els tipus de variables i els valors que contenen.

A continuació es mostra un exemple:

```
data = read.csv("./data/adult_processed.csv")
```

```
str(data)
```

```
'data.frame':   32561 obs. of  15 variables:
 $ age           : int  39 50 38 53 28 37 49 52 31 42 ...
 $ workclass     : chr  "State-gov" "Self-emp-not-inc" "Private" "Private" ...
 $ fnlwgt        : int  77516 83311 215646 234721 338409 284582 160187 209642 45781 159449 ...
 $ education     : chr  "Bachelors" "Bachelors" "HS-grad" "11th" ...
 $ education.num : int  13 13 9 7 13 14 5 9 14 13 ...
 $ marital.status: chr  "Never-married" "Married-civ-spouse" "Divorced" "Married-civ-spouse" ...
 $ occupation    : chr  "Adm-clerical" "Exec-managerial" "Handlers-cleaners" "Handlers-cleaners" ...
 $ relationship  : chr  "Not-in-family" "Husband" "Not-in-family" "Husband" ...
 $ race          : chr  "White" "White" "White" "Black" ...
 $ sex           : chr  "Male" "Male" "Male" "Male" ...
 $ capital.gain  : int  2174 0 0 0 0 0 0 0 14084 5178 ...
 $ capital.loss  : int  0 0 0 0 0 0 0 0 0 0 ...
 $ hours.per.week: int  40 13 40 40 40 40 16 45 50 40 ...
 $ native.country: chr  "United-States" "United-States" "United-States" "United-States" ...
 $ income        : chr  "<=50K" "<=50K" "<=50K" "<=50K" ...
```

```
summary(data)
```

```
      age          workclass            fnlwgt          education         education.num   marital.status    
 Min.   :17.00   Length:32561       Min.   :  12285   Length:32561       Min.   : 1.00   Length:32561      
 1st Qu.:28.00   Class :character   1st Qu.: 117827   Class :character   1st Qu.: 9.00   Class :character  
 Median :37.00   Mode  :character   Median : 178356   Mode  :character   Median :10.00   Mode  :character  
 Mean   :38.58                      Mean   : 189778                      Mean   :10.08                     
 3rd Qu.:48.00                      3rd Qu.: 237051                      3rd Qu.:12.00                     
 Max.   :90.00                      Max.   :1484705                      Max.   :16.00                     
  occupation        relationship          race               sex            capital.gain    capital.loss   
 Length:32561       Length:32561       Length:32561       Length:32561       Min.   :    0   Min.   :   0  
 Class :character   Class :character   Class :character   Class :character   1st Qu.:    0   1st Qu.:   0  
 Mode  :character   Mode  :character   Mode  :character   Mode  :character   Median :    0   Median :   0  
                                                                             Mean   : 1078   Mean   :  87  
                                                                             3rd Qu.:    0   3rd Qu.:   0  
                                                                             Max.   :99999   Max.   :4356  
 hours.per.week  native.country        income         
 Min.   : 1.00   Length:32561       Length:32561       
 1st Qu.:40.00   Class :character   Class :character   
 Median :40.00   Mode  :character   Mode  :character   
 Mean   :40.44                                         
 3rd Qu.:45.00                                         
 Max.   :99.00                                         
```

```
describe(data)
```

```
# A tibble: 15 × 26
   described_variables n_obs     mean       sd    se_mean      IQR    skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
   <chr>               <int>     <dbl>    <dbl>      <dbl>    <dbl>     <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
 1 age                 32561    38.6     13.6       0.0753   20          0.558   -0.185    17    17    17    22    25    28    30    34    37    41    44    48    52    65    72    77    90
 2 workclass           32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 3 fnlwgt              32561 189778.  105550.       585.    118774.      1.45     6.22   12285 13769 37870 48420 97421 117827 137190 158331 178356 202822 229072 237051 283879 379682 548568 1484705
 4 education           32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 5 education.num       32561    10.1      2.57      0.0142    3          -0.311   0.619      1     3     5     7     9     9    10    10    10    11    12    13    14    15    16    16    16
 6 marital.status      32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 7 occupation          32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 8 relationship        32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 9 race                32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
10 sex                 32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
11 capital.gain        32561  1078.    7385.       40.9       0          11.9    145.       0     0     0     0     0     0     0     0     0     0     0     0     0  5178  7298 14344 99999
12 capital.loss        32561    87.3    403.        2.23      0           4.59    20.5      0     0     0     0     0     0     0     0     0     0     0     0     0   1902  1977  2415  4356
13 hours.per.week      32561    40.4     12.3       0.0683    5           0.228    2.91     1     8    24    32    35    40    40    40    40    40    45    45    48    60    72    80    99
14 native.country      32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
15 income              32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$age)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 age                 32561  38.6  13.6  0.0753    20    0.558   -0.185    17    17    17    22    25    28    30    34    37    41    44    48    52    65    72    77    90
```

```
describe(data$workclass)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 workclass           32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$fnlwgt)
```

```
# A tibble: 1 × 26
  described_variables n_obs   mean     sd se_mean    IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int>  <dbl>  <dbl>   <dbl>  <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 fnlwgt              32561 189778. 105550.    585. 118774.     1.45     6.22 12285 13769 37870 48420 97421 117827 137190 158331 178356 202822 229072 237051 283879 379682 548568 1484705
```

```
describe(data$education)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 education           32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$education.num)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 education.num       32561  10.1  2.57  0.0142     3   -0.311    0.619     1     3     5     7     9     9    10    10    10    11    12    13    14    15    16    16    16
```

```
describe(data$marital.status)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 marital.status      32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$occupation)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 occupation          32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$relationship)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 relationship        32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$race)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 race                32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$sex)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 sex                 32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$capital.gain)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 capital.gain        32561  1078.  7385.    40.9     0     11.9      145.     0     0     0     0     0     0     0     0     0     0     0     0     0  5178  7298 14344 99999
```

```
describe(data$capital.loss)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 capital.loss        32561  87.3  403.     2.23     0      4.59     20.5     0     0     0     0     0     0     0     0     0     0     0     0     0  1902  1977  2415  4356
```

```
describe(data$hours.per.week)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 hours.per.week      32561  40.4  12.3  0.0683     5    0.228     2.91     1     8    24    32    35    40    40    40    40    40    45    45    48    60    72    80    99
```

```
describe(data$native.country)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 native.country      32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$income)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 income              32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

Estadístiques Descriptives

L'estadística descriptiva és una branca de l'estadística que s'ocupa de resumir i descriure les característiques principals d'un conjunt de dades. Aquestes estadístiques ens donen una idea de la tendència central, la dispersió i la forma de la distribució de les dades.

Per exemple, la mitjana ens indica el valor central de les dades, mentre que la desviació estàndard ens indica com de dispersos estan els valors respecte a la mitjana. L'assimetria ens indica si les dades estan distribuïdes de manera simètrica o si hi ha una cua més llarga a un costat que a l'altre. La curtosi ens indica si les dades tenen més o menys valors extrems que una distribució normal.

Per calcular aquestes estadístiques, podem utilitzar funcions com `mean()`, `sd()`, `skewness()` i `kurtosis()`. Aquestes funcions ens donen els valors corresponents per a una variable numèrica.

A continuació es mostra un exemple:

```
describe(data)
```

```
# A tibble: 15 × 26
   described_variables n_obs     mean       sd    se_mean      IQR    skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
   <chr>               <int>     <dbl>    <dbl>      <dbl>    <dbl>     <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
 1 age                 32561    38.6     13.6       0.0753   20          0.558   -0.185    17    17    17    22    25    28    30    34    37    41    44    48    52    65    72    77    90
 2 workclass           32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 3 fnlwgt              32561 189778.  105550.       585.    118774.      1.45     6.22   12285 13769 37870 48420 97421 117827 137190 158331 178356 202822 229072 237051 283879 379682 548568 1484705
 4 education           32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 5 education.num       32561    10.1      2.57      0.0142    3          -0.311   0.619      1     3     5     7     9     9    10    10    10    11    12    13    14    15    16    16    16
 6 marital.status      32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 7 occupation          32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 8 relationship        32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
 9 race                32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
10 sex                 32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
11 capital.gain        32561  1078.    7385.       40.9       0          11.9    145.       0     0     0     0     0     0     0     0     0     0     0     0     0  5178  7298 14344 99999
12 capital.loss        32561    87.3    403.        2.23      0           4.59    20.5      0     0     0     0     0     0     0     0     0     0     0     0     0   1902  1977  2415  4356
13 hours.per.week      32561    40.4     12.3       0.0683    5           0.228    2.91     1     8    24    32    35    40    40    40    40    40    45    45    48    60    72    80    99
14 native.country      32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
15 income              32561    NA       NA        NA        NA         NA       NA        NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$age)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 age                 32561  38.6  13.6  0.0753    20    0.558   -0.185    17    17    17    22    25    28    30    34    37    41    44    48    52    65    72    77    90
```

```
describe(data$workclass)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 workclass           32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$fnlwgt)
```

```
# A tibble: 1 × 26
  described_variables n_obs   mean     sd se_mean    IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int>  <dbl>  <dbl>   <dbl>  <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 fnlwgt              32561 189778. 105550.    585. 118774.     1.45     6.22 12285 13769 37870 48420 97421 117827 137190 158331 178356 202822 229072 237051 283879 379682 548568 1484705
```

```
describe(data$education)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 education           32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$education.num)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 education.num       32561  10.1  2.57  0.0142     3   -0.311    0.619     1     3     5     7     9     9    10    10    10    11    12    13    14    15    16    16    16
```

```
describe(data$marital.status)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 marital.status      32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$occupation)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 occupation          32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$relationship)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 relationship        32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$race)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 race                32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$sex)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 sex                 32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$capital.gain)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 capital.gain        32561  1078.  7385.    40.9     0     11.9      145.     0     0     0     0     0     0     0     0     0     0     0     0     0  5178  7298 14344 99999
```

```
describe(data$capital.loss)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 capital.loss        32561  87.3  403.     2.23     0      4.59     20.5     0     0     0     0     0     0     0     0     0     0     0     0     0  1902  1977  2415  4356
```

```
describe(data$hours.per.week)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 hours.per.week      32561  40.4  12.3  0.0683     5    0.228     2.91     1     8    24    32    35    40    40    40    40    40    45    45    48    60    72    80    99
```

```
describe(data$native.country)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 native.country      32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

```
describe(data$income)
```

```
# A tibble: 1 × 26
  described_variables n_obs  mean    sd se_mean   IQR skewness kurtosis   p00   p01   p05   p10   p20   p25   p30   p40   p50   p60   p70   p75   p80   p90   p95   p99  p100
  <chr>               <int> <dbl> <dbl>   <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 income              32561    NA    NA      NA    NA       NA       NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA    NA
```

Visualitzacions

Histogrames

```
ggplot(data, aes(x = fnlwgt)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  labs(title = "Distribució de fnlwgt", x = "fnlwgt", y = "Freqüència")
```

```
ggplot(data, aes(x = fnlwgt, fill = income)) +
  geom_histogram(bins = 30, color = "white", alpha = 0.7, position = "identity") +
  labs(title = "Distribució de fnlwgt per income", x = "fnlwgt", y = "Freqüència", fill = "income")
```


Boxplots

```
ggplot(data, aes(x = income, y = fnlwgt, fill = income)) +
  geom_boxplot() +
  labs(title = "Boxplot de fnlwgt per income", x = "income", y = "fnlwgt")
```


Gràfics de barres

```
ggplot(data, aes(x = workclass)) +
  geom_bar(fill = "steelblue") +
  labs(title = "Distribució de workclass", x = "workclass", y = "Freqüència")
```

```
ggplot(data, aes(x = workclass, fill = income)) +
  geom_bar(position = "dodge") +
  labs(title = "Distribució de workclass per income", x = "workclass", y = "Freqüència", fill = "income")
```


Scatterplots

```
ggplot(data, aes(x = age, y = fnlwgt)) +
  geom_point(alpha = 0.5) +
  labs(title = "Scatterplot de age i fnlwgt", x = "age", y = "fnlwgt")
```

```
ggplot(data, aes(x = age, y = fnlwgt, color = income)) +
  geom_point(alpha = 0.5) +
  labs(title = "Scatterplot de age i fnlwgt per income", x = "age", y = "fnlwgt", color = "income")
```


Matrius de correlació

```
correlate(data) %>% plot()
```


Gràfics de densitat

```
ggplot(data, aes(x = fnlwgt)) +
  geom_density(fill = "steelblue", color = "white") +
  labs(title = "Distribució de fnlwgt", x = "fnlwgt", y = "Densitat")
```

```
ggplot(data, aes(x = fnlwgt, fill = income)) +
  geom_density(color = "white", alpha = 0.7, position = "identity") +
  labs(title = "Distribució de fnlwgt per income", x = "fnlwgt", y = "Densitat", fill = "income")
```


Gràfics de violí

```
ggplot(data, aes(x = income, y = fnlwgt, fill = income)) +
  geom_violin() +
  labs(title = "Violin plot de fnlwgt per income", x = "income", y = "fnlwgt")
```


Gràfics de línies

```
ggplot(data, aes(x = age, y = fnlwgt)) +
  geom_line() +
  labs(title = "Gràfic de línies de age i fnlwgt", x = "age", y = "fnlwgt")
```

```
ggplot(data, aes(x = age, y = fnlwgt, color = income)) +
  geom_line() +
  labs(title = "Gràfic de línies de age i fnlwgt per income", x = "age", y = "fnlwgt", color = "income")
```


Gràfics de pastís

```
ggplot(data, aes(x = "", fill = workclass)) +
  geom_bar(width = 1) +
  coord_polar("y") +
  labs(title = "Gràfic de pastís de workclass", fill = "workclass")
```

```
ggplot(data, aes(x = "", fill = workclass)) +
  geom_bar(width = 1) +
  coord_polar("y") +
  facet_wrap(~income) +
  labs(title = "Gràfic de pastís de workclass per income", fill = "workclass")
```


Gràfics de dispersió amb línies de regressió

```
ggplot(data, aes(x = age, y = fnlwgt)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title = "Scatterplot de age i fnlwgt amb línia de regressió", x = "age", y = "fnlwgt")
```

```
ggplot(data, aes(x = age, y = fnlwgt, color = income)) +
```

MLGz - Numerical response

2024-11-02

Introducció

Comprendre els factors que influeixen en els nivells d'insulina és essencial per poder avançar en eines de diagnòstic i tractament de la diabetes. Per a això, aquesta part del projecte es centra en evaluar com les diferències variables (tan observacionals d'hàbits com d'estil de vida) afecten a aquests nivells. Per això, s'ha creat un model lineal generalitzat (MLG) i tal i com apareix en l'objectiu principal, així també també una utilitat com a base per a entregar el factors de diagnòstic que podria el pacient en futures investigacions, donat que cadascun afecta als nivells d'insulina d'una manera diferent.

Aquest model l'utilitzarem per dictar quines variables es relacionen o no amb la resposta mitjançant l'observació del p-valor sobre cada paràmetre, mirant així si aquesta es influent (<=0.05) o no.

Creació del model

Selecció de les variables per al model

Primer, realitzarem un model lineal generalitzat amb el nivell d'insulina com a variable resposta i totes les variables (hauent descartat prèviament les que no era interessants) en el preprocessament com a explicatives, evitement també la variable "Target", ja que el fluxo de diabetes que és el determina els resultats d'insulina.

Aquest model l'utilitzarem per dictar quines variables es relacionen o no amb la resposta mitjançant l'observació del p-valor sobre cada paràmetre, mirant així si aquesta es influent (<=0.05) o no.

```
delps_1 <- glm(Insulin.Levels ~ . -Target, family=gaussian, data)
summary(delps_1)
```

```
##
## Call:
## glm(formula = Insulin.Levels ~ . - Target, family = gaussian,
##     data = data)
##
## Coefficients:
##                                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  -1.605e+01  2.231e-01 -71.975  <2e-16 ***
## Genetic.MutationsPositive     2.311e-01  3.051e-02   7.574 3.84e-14 ***
## Autoantibodies2Positive       2.313e-02  3.051e-02   0.415  0.6778
## Family.HistoryYes             2.313e-02  3.051e-02   0.415  0.6778
## Environmental.FactorsPresent  2.417e-02  3.050e-02   0.792  0.4284
## Age                           9.728e-02  2.496e-03  38.987  <2e-16 ***
## BMI                           2.464e-01  7.295e-03  33.778  <2e-16 ***
## Physical.ActivityLow         -3.473e-02  7.418e-02  -0.536  0.5920
## Physical.ActivityModerate     1.564e-01  7.418e-02   2.108  0.0350 *
## Dietary.HabitsUnhealthy       9.441e-02  4.050e-02   2.331  0.0198 *
## Blood.Pressure                6.688e-02  2.658e-03  25.456  <2e-16 ***
## Cholesterol.Levels            1.784e-02  1.064e-03  16.774  <2e-16 ***
## Waist.CircumferenceYes        2.263e-01  7.356e-03  30.843  <2e-16 ***
## Blood.Glucose.Levels          2.333e-01  1.064e-03 219.281  <2e-16 ***
## Metabolic.Syn.FactorsYes      2.214e-02  4.050e-02   0.547  0.5847
## Socioeconomic.FactorsYes     -3.129e-02  7.418e-02  -0.421  0.6736
## Socioeconomic.FactorsMedium  -9.392e-03  7.418e-02  -0.127  0.8992
## Smoking.StatusSmoker          1.229e-02  4.050e-02   0.303  0.7596
## Alcohol.ConsumptionYes        1.229e-02  7.418e-02   0.166  0.8683
## History.of.PCOSYes            4.469e-02  4.050e-02   1.104  0.2699
## History.of.PCOSTrue           4.917e-02  7.418e-02   0.663  0.5074
## Previous.Gestational.DiabetesYes -7.778e-02  4.051e-02  -1.920  0.0550 .
## Pancreatic.HealthYes          4.053e-03  1.864e-03   2.173  0.0298 *
## Liver.Function.TestsNormal    2.354e-01  5.950e-02   3.956 7.67e-05 ***
## Urine.Test.KetonesPresent     3.233e-01  8.379e-02   3.858  0.0001 ***
## Urine.Test.GlucosePresent     1.233e-01  8.379e-02   1.472  0.1412
## Urine.Test.ProteinPresent     1.344e-02  8.351e-02   0.161  0.8724
## Birth.WeightNormal            9.706e-04  5.750e-05  17.012  <2e-16 ***
## Family.Const.SymptomsYes      7.105e-01  5.950e-02  11.941  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 64.03556)
##
##     Null deviance: 814306  on 49999  degrees of freedom
## Residual deviance: 480297  on 49951  degrees of freedom
## AIC: 489863
##
## Number of Fisher Scoring iterations: 2
```

Primerament, veiem que el model amb variables explica més que el nul (NUll deviance >> Residual Deviance), per tant, deduim que diverses d'aquestes influeixen sobre el resultat de la variable objectiu.

Observem que l'edat, el BMI, la pressió arterial, els resultats de colesterol, la circumferència de la cintura, els nivells de glucosa en sang i en pet al retxan han obtingut uns p-valor molt significatius, indicant que influeixen molt al resultat.

Per això, durem a terme un MLGz amb les variables més significatives.

```
delps_v <- glm(Insulin.Levels ~ Age + BMI + Blood.Pressure + Cholesterol.Levels + Waist.Circumference + Blood.Glucose.Levels + Birth.Weight, family=gaussian, data)
summary(delps_v)
```

```
##
## Call:
## glm(formula = Insulin.Levels ~ Age + BMI + Blood.Pressure + Cholesterol.Levels +
##     Waist.Circumference + Blood.Glucose.Levels + Birth.Weight,
##     family = gaussian, data = data)
##
## Coefficients:
##                              Estimate Std. Error t value Pr(>|t|)
## (Intercept)                -1.597e+01  2.213e-01 -72.162  <2e-16 ***
## Age                         9.737e-02  2.479e-03  39.277  <2e-16 ***
## BMI                         2.467e-01  7.244e-03  34.057  <2e-16 ***
## Blood.Pressure              6.687e-02  2.643e-03  25.305  <2e-16 ***
## Cholesterol.Levels          2.778e-02  1.063e-03  26.141  <2e-16 ***
## Waist.CircumferenceYes      2.273e-01  7.303e-03  31.132  <2e-16 ***
## Blood.Glucose.Levels        2.333e-01  1.063e-03 219.538  <2e-16 ***
## Birth.Weight                9.670e-04  5.694e-05  16.985  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for gaussian family taken to be 64.04756)
##
##     Null deviance: 814306  on 49999  degrees of freedom
## Residual deviance: 480760  on 49992  degrees of freedom
## AIC: 489863
##
## Number of Fisher Scoring iterations: 2
```

Una vegada realitzat aquest, passarem a comprovar les possibles interaccions entre les nostres variables.

Model amb interacció

Ara durem a terme un model amb totes les interaccions per veure si l'efecte de les variables sobre la resposta depenen del valor d'altres, així ho farem mitjançant l'observació del p-valor de cadascuna de les interaccions per si es rellevant incloure-les al model.

```
delps_int <- glm(Insulin.Levels ~ (Age + BMI + Blood.Pressure + Cholesterol.Levels + Waist.Circumference + Blood.Glucose.Levels + Birth.Weight)^2, family=gaussian, data)
```

Executat és observem que la majoria de les nostres variables interaccion entre elles (a una influència en la variable resposta depén de les altres), per tant, inclourem les interaccions més significatives (p-valor <== 0.05) al model, comprovant a la devidesa residual que així ha millorat el nostre model:

```
delps_i <- glm(Insulin.Levels ~ Age + BMI + Blood.Pressure + Cholesterol.Levels + Waist.Circumference + Blood.Glucose.Levels + Birth.Weight + Age*BMI + Age*Blood.Pressure + Age*Cholesterol.Levels + Age*Waist.Circumference + Age*Blood.Glucose.Levels + Age*Birth.Weight + BMI*Blood.Pressure + BMI*Cholesterol.Levels + BMI*Waist.Circumference + BMI*Blood.Glucose.Levels + BMI*Birth.Weight + Blood.Pressure*Cholesterol.Levels + Blood.Pressure*Waist.Circumference + Blood.Pressure*Blood.Glucose.Levels + Blood.Glucose.Levels*Waist.Circumference + Blood.Glucose.Levels*Birth.Weight, family=gaussian, data)

## Deviancia residual nova interacció: 4182780

## Deviancia residual amb interacció: 4176428
```

Elecció de la família i link

A continuació, determinarem la família i funció link a utilitzar, provant amb la Gaussiana, la Gamma i la inversa Gaussiana

Gaussian

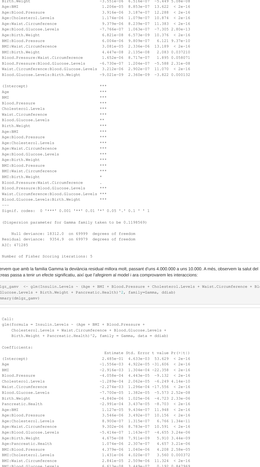

Gamma

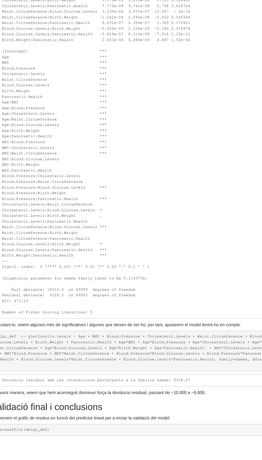

Inverse Gaussian

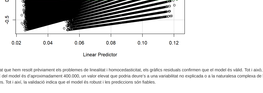

La família Gamma es la que dona millors resultats, donat que és la que millor compleix la linealitat i homocedasticitat. Per tant, ens quedarem amb la Gamma, comprovant abans que no ens faci alcun que variable o interaccions importants:

```
delps_gam_1 <- glm(Insulin.Levels ~ . -Target, family=Gamma, data)
summary(delps_gam)
```

```
##
## Call:
## glm(formula = Insulin.Levels ~ Age + BMI + Blood.Pressure + Cholesterol.Levels +
##     Waist.Circumference + Blood.Glucose.Levels + Birth.Weight +
##     Age * BMI + Age * Blood.Pressure + Age * Cholesterol.Levels +
##     Age * Waist.Circumference + Age * Blood.Glucose.Levels +
##     Age * Birth.Weight + BMI * Blood.Pressure + BMI * Waist.Circumference +
##     BMI * Birth.Weight + Blood.Pressure * Waist.Circumference +
##     Blood.Pressure * Blood.Glucose.Levels + Blood.Glucose.Levels *
##     Waist.Circumference + Blood.Glucose.Levels * Birth.Weight,
##     family = Gamma, data = data)
##
## Coefficients:
##                                          Estimate Std. Error t value Pr(>|t|)
## (Intercept)                          -3.564e-01  3.975e-01  -0.751  0.45314
## Age                                  -1.475e-03  4.427e-05 -17.737  < 2e-16
## BMI                                  -3.163e-03  1.189e-04 -26.614  < 2e-16
## Blood.Pressure                       -3.913e-04  3.412e-05 -11.470  < 2e-16
## Cholesterol.Levels                   -1.284e-04  1.366e-05  -9.401  < 2e-16
## Waist.CircumferenceYes               -3.004e-03  1.115e-04 -26.937  < 2e-16
## Blood.Glucose.Levels                 -1.354e-03  1.332e-05 -101.657  < 2e-16
## Birth.Weight                         -3.551e-06  6.514e-07  -5.449 5.09e-08
## Age:BMI                               1.204e-05  8.833e-07  13.632  < 2e-16
## Age:Blood.Pressure                    1.178e-06  6.805e-07   1.731  0.08345
## Age:Cholesterol.Levels                1.178e-06  2.275e-07   5.179  2.2e-07
## Age:Waist.CircumferenceYes            9.379e-06  2.229e-07  11.383  < 2e-16
## Age:Blood.Glucose.Levels              7.784e-07  1.063e-07   7.320 2.49e-13
## Age:Birth.Weight                      6.631e-08  8.574e-09  10.376  < 2e-16
## BMI:Blood.Pressure                    1.054e-05  9.909e-07  10.633  < 2e-16
## BMI:Waist.CircumferenceYes            3.041e-05  2.116e-06  14.371  < 2e-16
## BMI:Birth.Weight                      1.351e-07  1.686e-08   8.013 1.14e-15
## Blood.Pressure:Waist.CircumferenceYes 1.452e-06  6.717e-07   2.161  0.03071
## Blood.Pressure:Blood.Glucose.Levels   -4.734e-07  1.228e-07  -3.856 0.000116
## Waist.CircumferenceYes:Blood.Glucose.Levels 2.112e-06  2.052e-07  10.292  < 2e-16
## Blood.Glucose.Levels:Birth.Weight     -9.011e-09  2.166e-09  -4.162 0.000032
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.1194569)
##
##     Null deviance: 18312.0  on 49999  degrees of freedom
## Residual deviance:  5974.9  on 49970  degrees of freedom
## AIC: 471185
##
## Number of Fisher Scoring iterations: 5
```

Observem que amb la família Gamma la devidesa residual millora molt, passant d'uns 4.000.000 a uns 10.000. A més, observem la salut del pànorcies passa a ser un efecte significatiu, així que l'afegirem al model i així a comprovarem les interaccions:

```
delps_gam <- glm(Insulin.Levels ~ (Age + BMI + Blood.Pressure + Cholesterol.Levels + Waist.Circumference + Blood.Glucose.Levels + Birth.Weight + Pancreatic.Health)^2, family=Gamma, data)
summary(delps_gam)
```

```
##
## Call:
## glm(formula = Insulin.Levels ~ (Age + BMI + Blood.Pressure +
##     Cholesterol.Levels + Waist.Circumference + Blood.Glucose.Levels +
##     Birth.Weight + Pancreatic.Health)^2, family = Gamma, data = data)
##
## Coefficients:
##                                          Estimate Std. Error t value Pr(>|t|)
## (Intercept)                          2.469e-01  6.619e-03  37.629  < 2e-16
## Age                                 -1.503e-03  4.562e-05 -32.956  < 2e-16
## BMI                                 -2.916e-03  1.318e-04 -22.058  < 2e-16
## Blood.Pressure                      -3.913e-04  3.412e-05 -11.470  < 2e-16
## Cholesterol.Levels                  -1.228e-04  1.366e-05  -8.984  < 2e-16
## Waist.CircumferenceYes              -2.273e-03  1.236e-04 -17.556  < 2e-16
## Blood.Glucose.Levels                -1.356e-03  1.332e-05 -101.832  < 2e-16
## Birth.Weight                        -4.849e-06  1.025e-06  -4.732 2.2e-06
## Pancreatic.HealthYes                -1.127e-03  1.864e-04  -6.048 1.48e-09
## Age:BMI                              1.204e-05  8.833e-07  13.632  < 2e-16
## Age:Blood.Pressure                   1.164e-06  6.804e-07   1.710  0.08731
## Age:Cholesterol.Levels               8.905e-07  2.275e-07   3.914 9.11e-05
## Age:Waist.CircumferenceYes           9.355e-06  2.229e-07  41.970  < 2e-16
## Age:Blood.Glucose.Levels             7.784e-07  1.063e-07   7.320 2.49e-13
## Age:Birth.Weight                     6.631e-08  8.574e-09  10.376  < 2e-16
## Age:Pancreatic.Health                1.178e-06  2.275e-07   5.179  2.2e-07
## BMI:Blood.Pressure                   1.054e-05  9.909e-07  10.633  < 2e-16
## BMI:Cholesterol.Levels               1.414e-06  4.028e-07   3.510 0.000737
## BMI:Waist.CircumferenceYes           3.041e-05  2.116e-06  14.371  < 2e-16
## BMI:Blood.Glucose.Levels             6.913e-08  3.448e-07   0.201 0.840749
## BMI:Birth.Weight                     1.351e-07  1.686e-08   8.013 1.14e-15
## BMI:Pancreatic.Health                7.534e-07  3.880e-06   0.194 0.846119
## Blood.Pressure:Cholesterol.Levels    -1.427e-07  1.529e-07  -0.278 0.780930
## Blood.Pressure:Waist.CircumferenceYes -1.452e-06  6.717e-07  -2.161 0.030711
## Blood.Pressure:Blood.Glucose.Levels  -5.144e-07  1.239e-07  -4.041 5.34e-05
## Blood.Pressure:Birth.Weight          -1.004e-09  1.944e-09  -0.516 0.605727
## Blood.Pressure:Pancreatic.Health     -1.886e-06  2.673e-07  -7.061 1.66e-12
## Cholesterol.Levels:Waist.CircumferenceYes 8.045e-06  2.441e-07  32.952 0.814395
## Cholesterol.Levels:Blood.Glucose.Levels 3.169e-07  6.757e-08   4.690 2.73e-06
## Cholesterol.Levels:Birth.Weight      5.573e-09  3.233e-09   1.724 0.084692
## Cholesterol.Levels:Pancreatic.Health -1.178e-06  2.275e-07  -5.179  2.2e-07
## Waist.CircumferenceYes:Blood.Glucose.Levels 2.112e-06  2.052e-07  10.287  < 2e-16
## Waist.CircumferenceYes:Birth.Weight  -1.245e-08  2.595e-08  -0.480 0.564844
## Waist.CircumferenceYes:Pancreatic.Health 8.431e-07  6.308e-07   1.368 0.170911
## Blood.Glucose.Levels:Birth.Weight    -9.523e-09  2.524e-09  -3.774 0.000159
## Blood.Glucose.Levels:Pancreatic.Health -1.886e-06  2.673e-07  -7.061 1.66e-12
## Birth.Weight:Pancreatic.Health       -3.671e-08  5.468e-09  -6.697 2.16e-11
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.1193744)
##
##     Null deviance: 18312.0  on 49999  degrees of freedom
## Residual deviance:  5928.7  on 49943  degrees of freedom
## AIC: 471117
##
## Number of Fisher Scoring iterations: 5
```

Executant-lo, veiem algunes més de significatives i algunes que deroen de ser-ho, per tant, ajustarem el model tenint-ho en compte:

```
delps_def <- glm(Insulin.Levels ~ Age + BMI + Blood.Pressure + Cholesterol.Levels + Waist.Circumference + Blood.Glucose.Levels + Birth.Weight + Pancreatic.Health + Age*BMI + Age*Blood.Pressure + Age*Waist.Circumference + Age*Blood.Glucose.Levels + Age*Pancreatic.Health + BMI*Cholesterol.Levels + BMI*Blood.Pressure + BMI*Waist.CircumferenceYes + Blood.Pressure*Blood.Glucose.Levels + Blood.Pressure*Pancreatic.Health + Blood.Glucose.Levels*Waist.CircumferenceYes + Blood.Glucose.Levels*Pancreatic.Health, family=Gamma, data)

## Deviancia residual amb les interaccions pertinents a la família Gamma: 5934.67
```

D'aquest manera, veiem que hem aconseguit disminuir força la devidencia residual, passant de ~10.000 a ~6.000.

Validació final i conclusions

Empraran el gràfic de residus en funció del predictor lineal per a iniciar la validació del model.

```
residualPlot(delps_def)
```


Donat que hem resolt primerament els problemes de linealitat i homocedasticitat, els gràfics residuals confirmen que el model és vàlid. Tot i això, l'AIC del model és d'aproximadament 400.000, el que indica que el model pot millorar-se encara més a una variabilitat no explicada o a la naturalesa complexa de les dades. Tot i així, la validació indica que el model és robust i les prediccions són fiables.

Binary Response

2024-11-02

Introducció

La finalitat d'aquest script és el de trobar un model que s'ajusti a les nostres dades i validar ho.
La variable a predir és Cholesterol.Category, una variable binaria amb dues categories, una pel als individus amb valors de *colesterol* considerats per sota del llindar de risk, i un altre per a tots aquells individus valors que superen aquest llindar.
Aquesta variable la hem obtingut de manera "artificial", dicotomitzant la variables Cholesterol.Levels separant els seus valors en dues categories en funció si aquests eren inferiors o superiors al valor del llindar de colesterol alt.
Volem veure com les següents variables afecten al valor d'aquesta variable resposta:
- Age
- Blood.Pressure
- BMI
- Insulin.Levels

Per utilitzar aquest script, utilitzem la base de dades "base_treball.csv. que es una versió de la base principal processed a la que hem afegit la variable Cholesterol.Category.

Model amb dades desagregades

Creem un primer model amb dades desagregades en el que intentem predir la variable *Cholesterol.Category* a partir de les nostres variables.
La predicció es realitza mitjançant la unió de la intercepció de cadascuna de les variables que tenim amb la variable Age.

```
m_desagregades <- glm(Cholesterol.Category ~ Age * Blood.Pressure * Age * BMI
                                           + Age * Insulin.Levels,
                      data = data,
                      family = binomial(link = "logit"))
summary(m_desagregades)
```

```
##
## Call:
## glm(formula = Cholesterol.Category ~ Age * Blood.Pressure * Age *
##     BMI + Age * Insulin.Levels, family = binomial(link = "logit"),
##     data = data)
##
## Coefficients:
##                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)           -3.457e+01  6.684e-01 -51.70  <2e-16 ***
## Age                    8.977e-01  1.243e-02  72.23  <2e-16 ***
## Blood.Pressure         1.724e-01  4.766e-03  36.32  <2e-16 ***
## BMI                    2.141e-01  1.149e-02  18.31  <2e-16 ***
## Insulin.Levels         1.213e-01  5.337e-03  22.74  <2e-16 ***
## Age:Blood.Pressure    -2.523e-03  2.173e-04 -11.61  <2e-16 ***
## Age:BMI               -2.913e-03  2.417e-04 -12.05  <2e-16 ***
## Age:Insulin.Levels    -1.725e-03  9.594e-05 -17.98  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 61437  on 69999  degrees of freedom
## Residual deviance: 37841  on 69992  degrees of freedom
## AIC: 37858
##
## Number of Fisher Scoring iterations: 8
```

Podem veure com els p-valors de cadascuna de les variables i interaccions són inferior a 0.05. Això ens deixa veure que aquestes variables són significatives a l'hora de determinar el valor de la nostra variable resposta.
Veiem que mentres que les variables de manera individual mostren coeficients positius, fent que el valor de la variable resposta augmenti quan el seu ho fa, les 3 interaccions proposades tenen coeficients negatius, mostrant una relació inversa amb el creixement de *Cholesterol.Category*.
Per altra banda, el valor de la desviació Residual és considerablement inferior al de la Desviació Nula. Això deixa veure que el model que hi en compte les variables i aquestes milor que el model nul.
El nostre model té una desviança de 37841 i un total de 69992 graus de libertat.
El valor del AIC ens permetrà comparar el nostre model amb un altre, sabent que com més petit el AIC, millor és l'ajust del model.

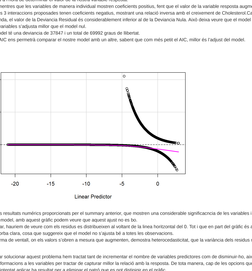

Tot i els bons resultats numèrics proporcionats per el summary anterior, que mostren una considerable significancia de les variables i un ajust correcte del model, amb aquest gràfic podem veure que aquest ajust no es tan bo.
Per contrastar, hauriem de veure com els residus es distribueixen al voltant de la línea horitzontal del 0. Tot i que en part bé gràfic és així, es pot veure una corba clara, cosa que suggereix que el model no s'ajusta bé a totes les observacions.
A més, la forma de ventall, on els valors s'obren a mesura que augmenten, demostra heteroscedasticitat, que la variància dels residus no és constant.
Per a intentar solucionar aquest problema hem tractat tant de incrementar el nombre de variables predictores com de disminuir-ho, així com aplicar transformacions a les variables per tractar de capturar millor la relació amb la resposta. Dos maneres, cap de les opcions que hem considerat i intentat aplicar ha resultat per a eliminar el patró que es pot distingir en el gràfic.
També hem considerat la opció de que l'error es trobi en la pròpia estructura de la nostra base de dades.

Model amb dades agregades

Creem un nou model amb dades agregades en el que intentem predir la variable *Cholesterol.Category* a partir de les nostres variables, però ara agrupem les dades respecte a les variables que utilitzarem.
La predicció es realitza mitjançant la unió de la intercepció de cadascuna de les variables que tenim amb la variable Age.

```
dfAgreg <- with(data, aggregate(x = cbind(ypop = Cholesterol.Category, ynp) ~
                                                  1 + Cholesterol.Category,
                                FUN = sum))
                                by = list(Insulin.Levels = Insulin.Levels,
                                          Age = Age, BMI = BMI,
                                          Blood.Pressure = Blood.Pressure),
m_agregades <- glm(cbind(ypop, ynp) ~ Age * Blood.Pressure * Age * BMI
                                      + Age * Insulin.Levels,
                   data = dfAgreg,
                   family = binomial(link= "logit"))
summary(m_agregades)
```

```
##
## Call:
## glm(formula = cbind(ypop, ynp) ~ Age * Blood.Pressure * Age *
##     BMI + Age * Insulin.Levels, family = binomial(link = "logit"),
##     data = dfAgreg)
##
## Coefficients:
##                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)           -3.457e+01  6.684e-01 -51.70  <2e-16 ***
## Age                    8.977e-01  1.243e-02  72.23  <2e-16 ***
## Blood.Pressure         1.724e-01  4.766e-03  36.32  <2e-16 ***
## BMI                    2.141e-01  1.149e-02  18.31  <2e-16 ***
## Insulin.Levels         1.213e-01  5.337e-03  22.74  <2e-16 ***
## Age:Blood.Pressure    -2.523e-03  2.173e-04 -11.61  <2e-16 ***
## Age:BMI               -2.913e-03  2.173e-04 -13.42  <2e-16 ***
## Age:Insulin.Levels    -1.725e-03  9.593e-05 -17.98  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 61147  on 64599  degrees of freedom
## Residual deviance: 37321  on 64592  degrees of freedom
## AIC: 37338
##
## Number of Fisher Scoring iterations: 8
```

En aquest cas també podem veure com tots els valors són significatius, ja que tenen p-valors inferiors a 0.05.
Les variables tenen coeficient positius i les interaccions negatius, igual que en el model desagregat. Aquests coeficients són exactament iguals que en el model de dades desagregat.

```
##                          Age       Age
## (Intercept)        -34.570 -34.570
## Age                  0.898   0.898
## Blood.Pressure       0.172   0.172
## BMI                  0.214   0.214
## Insulin.Levels       0.121   0.121
## Age:Blood.Pressure  -0.003  -0.003
## Age:BMI             -0.003  -0.003
## Age:Insulin.Levels  -0.002  -0.002
```

La única diferència que podem identificar en aquest model és una disminució de la Deviancia Residual respecte a la del model amb dades desagregades i els graus de libertat:

```
##            D_Deviance D_Degrees of freedom
##                 37847.07             69992.00
```

```
##            A_Deviance A_Degrees of freedom
##                 37320.59             64592.00
```

També podem comparar els valors AIC:

```
## Valor AIC per al model desagregat: 37863.07
```

```
## Valor AIC per al model agregat: 37338.19
```

Tot i que la diferència és mínima, com pot el valor AIC del model amb dades agregades és inferior al de les dades desagregades, considerem que el model amb dades agregades s'ajusta millor a les nostres dades que el model desagregat.

```
residualPlot(m_agregades)
```

En aquest gràfic ens tornem a trobar amb el fet de que el model podria no estar captant bé la informació de les dades, ja que es podria no estar ajustant correctament.
Podem veure que a la part dreta del gràfic, hi ha una gran concentració de residus que es desvien de la línea del 0.
A més, es detecta una possible heteroscedasticitat, ja que els residus semblen mostrar una distribució més dispersa cap a un costat del gràfic, indicant una variació no constant al llarg dels valors predits.
Per tant obtenim les mateixes conclusions que amb el gràfic del model amb dades desagregades.

Amb el model de dades agregades podem utilitzar un test amb l'estadístic de la devianza per a comprobar si el nostre model s'ajusta a les dades.

```
deviance <- m_agregades$deviance  # Deviance
df       <- m_agregades$df.res    # d'graus de llibertat
1 - pchisq(deviance, df)          # p-value for hypothesis test
```

```
## [1] 1
```

Aquest valor de 1 podria no ser real i no representar realment l'ajust del model.
Primerament, podria ser que aquest 1 es degués al fet de que la base de dades tingui un volum tan gran de dades (70000).
A més, un *p-valor* proper a 1 indica que la deviance del model és tan baixa que és molt improbable que la diferència respecte al model nul sigui significativa. En altres paraules, suggerma que el model no és millor que l'atzar.
Finalment, aquest 1 podria ser interpretat com que el model s'ajusta extremadament bé a les dades, mentre que les proves anteriors deixen veure que no és així.

Model penalitzat Firth

Degut al fet de que el model de dades desagregades ni el de agregades han estat capaços d'ajustar correctament le dades, recurrirem a un *model penalitzat Firth* per a tractar d'obtenir un model que ens permetrà predir la nostra variable resposta. Per fer-ho, primer creem el nostre model:

```
m_firth <- logistf(Cholesterol.Category ~ Age * Blood.Pressure * Age * BMI
                                        + Age * Insulin.Levels, data = data)
summary(m_firth)
```

```
## logistf(formula = Cholesterol.Category ~ Age * Blood.Pressure +
##     Age * BMI + Age * Insulin.Levels, data = data)
##
## Model fitted by Penalized ML
## Coefficients:
##                             coef     se(coef)    lower 0.95  upper 0.95 Chisq
## (Intercept)           -34.555826202 0.668333e-01 -35.874451484 -33.253973260   Inf
## Age                     0.897441077 1.239838e-02   0.873201671   0.921860687   Inf
## Blood.Pressure          0.172385125 4.766237e-03   0.163048737   0.181641241   Inf
## BMI                     0.214059476 1.149359e-02   0.191969000   0.236249351   Inf
## Insulin.Levels          0.121278539 5.334915e-03   0.110858203   0.131784399   Inf
## Age:Blood.Pressure     -0.002523053 9.445914e-05  -0.002693625  -0.002353596   Inf
## Age:BMI                -0.002911605 1.173447e-04  -0.003138070  -0.002684274   Inf
## Age:Insulin.Levels     -0.001724494 9.591292e-05  -0.001912982  -0.001536945   Inf
##                        method
## (Intercept)             2
## Age                     2
## Blood.Pressure          2
## BMI                     2
## Insulin.Levels          2
## Age:Blood.Pressure      2
## Age:BMI                 2
## Age:Insulin.Levels      2
##
## Method: 1-Wald, 2-Profile penalized log-likelihood, 3-None
##
## Likelihood ratio test=23918.89 on 7 df, p=0, n=70000
## Wald test = 9596.288 on 7 df, p = 0
```

Els p-valors (pi) i Chisq tenen valors extrems, 0 per els primers i infinit per als segons. Això és altament probable que sigui degut al gran nombre d'observacions de la nostra base de dades, per la que no representaria una incoherència o un problema.
Un cop tenim el nostre model creat, fem una serie de predicciones de la variable resposta amb el nostre model penalitzat.

```
predicciones_firth <- predict(m_firth, newdata = data, type = "response")
head(predicciones_firth)
```

```
##  [1] 5.226592e-11 6.921587e-08 7.441827e-02 3.125124e-04 7.592903e-05
##  [6] 1.149228e-01
```

Observem algunes d'aquestes prediccions.
Un valor de 0.7, per exemple, ens està explicant que el model assigna una probabilitat del 70% a què una observació específica pertanyi a la categoria positiva, en aquest cas, pertanyer a la categoria corresponent a High.

Validació

Com que aquest model sembla correcte y no ens causa cap incoherència, procedirem a validarlo com el nostre model per a predir la variable Cholesterol.Levels.
Primerament, emplearem una corba ROC (Receiver Operating Characteristic) i el seu AUC (Area Under the Curve) per a comprobar la qualitat de les prediccions del model.

```
roc_curve <- roc(data$Cholesterol.Category, predicciones_firth)
```

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```

```
plot(roc_curve, main = "ROC Curve - Model de Firth")
```

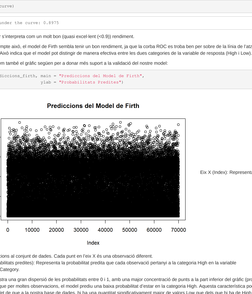

Veiem que la corba s'aproxa a l'angle superior esquerre del gràfic, cosa que indica que el model té una bona capacitat de discriminació entre les dues categories.
Com més fluty estigui la corba de la línia diagonal (línia de l'atzar), millor és el rendiment del model.

Veiem ara el valor AUC:

```
auc(roc_curve)
```

```
## Area under the curve: 0.8975
```

Aquest valor s'interpreta com un molt bon (quasi excel·lent (>0.9)) rendiment.

Tenint en compte això, el model de Firth sembla tenir un bon rendiment, ja que la corba ROC es troba ben per sobre de la línia de l'atzar i l'AUC és elevada. Això indica que el model pot distingir de manera efectiva entre les dues categories de la variable de resposta (High i Low).

Comprabarem també el gràfic segons per a donar més suport a la validació del nostre model:

```
plot(predicciones_firth, main = "Predicciones del Model de Firth",
                         ylab = "Probabilitats Predites")
```

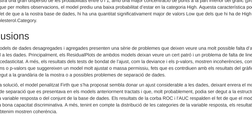

Els X (Index): Representa l'índex de les observacions al conjunt de dades. Cada punt en l'eix X és una observació diferent.
Els Y (Probabilitats predites): Representa la probabilitat predita que cada observació pertanyi a la categoria High en la variable Cholesterol.Category

El gràfic mostra una gran dispersió de les probabilitats entre 0 i 1, amb una major concentració de punts a la part inferior del gràfic (propa de 0). Això indica que per moltes observacions, el model prediu una baixa probabilitat d'estar en la categoria High. Aquesta característica podria ser donada pel fet de que a la base de dades, hi ha una quantitat significativament major de valors Low que dels que hi ha High per a la variable Cholesterol.Category.

Conclusions

1. Els models de dades desagregades i agregades presenten una sèrie de problemes que deixen veure una molt possible falta d'ajust del model a les dades. Principalment, els Residual/Plots de ambdos models deixan veure un cert patró i un problema de falta de linealitat i homocedasticitat. A més, els resultats dels tests de bondat de l'ajust, com la devianza i els p-valors, mostren incoherències, com ara valors extrems o p-valors que suggereixen un model molt ajustat o massa permissiu, fets que es contrediuen amb els resultats del gràfics, que pot ser degut a la grandaria de la mostra o a possibles problemes de sobreajust.
2. Com a solució, el model penalitzat Firth que s'ha proposat sembla donar un ajust considerable a les dades, deixant enrera el molt probable error de separació que es presentava en el model anterior. Aquest model ha aconseguit reduir l'impacte de les observacions extremes de la propia variable resposta o del conjunt de la base de dades. Els resultats de la corba ROC i l'AUC respaldan el fet de que el model de Firth té una bona capacitat discriminatòria. A més, tenint en compte la distribució de les categories de la variable resposta, els resultats gràfics que obtenim mostren coherència.

Sèries Temporals

2024-11-02

Introducció

L'objectiu d'aquesta anàlisi és descriure els patrons de la série temporal, estimar i validar els paràmetres i fer una predicció dels valors futurs.

La base de dades és una diferència de la que hem estat treballant fins ara, ja que no tenim cap variable temporal. La base de dades que utilitzem és una estimació de la vendes en el nombre d'automòbils (x10^3) venuts a l'estat de Virginia, a Estats Units de 1995 fins a 2006. El conjunt de dades consta de dos columnes una de les dades, que són mensuals, i una altra de les vendes. Te un total de 204 files.

Creem l'objecte 'ts'

```
Diabetes <- ts(df$Diabetes, start = 1995, frequency = 12)
plot(Diabetes)
```

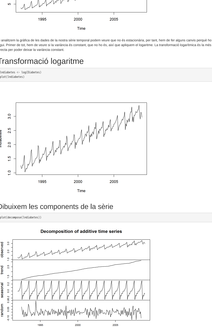

Si analitzem la gràfica de les dades de la nostra série temporal podem veure que no és estacionària, per tant, hem de fer algunes canvis perquè ho sigui. Podem veure que la série té una tendència creixent, que no hi ha res, així que aplicarem el logaritme, La transformació logarítmica és la més directa per poder donar la variància constant.

Transformació logaritme

```
Vehiclelog <- log(Vehicles)
plot(Vehiclelog)
```

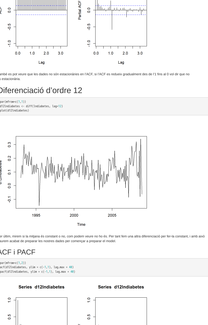

Dibuixem les components de la série

```
plot(decompose(Diabetes))
```

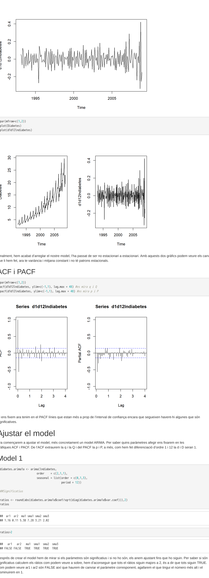

Ara la variància és constant, però com podem veure hi ha un patró estacional. És per això que farem ús de l'ordre diferenciació d'ordre 12, per eliure l'estacionalitat. Es d'ordre 12 perquè les nostres dades són mensuals i tenim la freqüència de les dades de 12.

ACF i PACF

```
par(mar=c(3,3))
acf(Vehicles, ylim=c(-1,1), lag.max = 40)
pacf(Vehicles, ylim=c(-1,1), lag.max = 40)
```

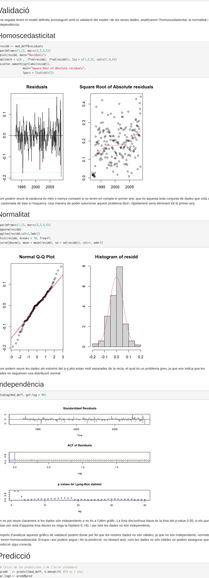

També es pot veure que les dades no són estacionàries en l'ACF, el retard estacionalment dels 0.1 fins al 0 vol de que no hi estacionaria.

Diferenciació d'ordre 12

```
par(mar=c(3,3))
plot(diff(Diabetes, lag=12))
plot(df$Diabetes)
```


Per últim, mirem si la sèrie és constant o no, com podem veure no ho és. Per tant fem una altra diferenciació per fer-la constant, i amb això haurem acabar de preparar les nostres dades per començar a proposar el model.

ACF i PACF

```
par(mar=c(3,3))
acf(df$Diabetes, ylim = c(-1,1), lag.max = 40)
pacf(df$Diabetes, ylim = c(-1,1), lag.max = 40)
```


En l'ACF i PACF ens podem fixar quins coeficients són significatius, si estrabassem les línies són significatius. Volem que hi hagi la quantitat mès pure possible de línies que estigui dins de l'interval de confiança, que és l'espai entre les dues discontinues blaves.

Diferenciació d'ordre 1

```
d12Diabetes <- diff(  d12Diabetes)
plot(df$Diabetes)
```



```
par(mar=c(3,3))
plot(Diabetes)
plot(df$Diabetes)
```


Finalment, fem acabat d'arreglar el nostre model. Fa passar de ser no estacionari a estacionari. Amb aquesta dins gràfics podem veure els cercles que li fem falta, ara té variància i mitjana constant i no té patrons estacionals.

ACF i PACF

```
par(mar=c(3,3))
acf(d12Diabetes, ylim=c(-1,1), lag.max = 40) #Ara mirem p i q
pacf(d12Diabetes, ylim=c(-1,1), lag.max = 40) #Ara mirem p i q
```


Si ens fixem ara bonic en el PACF diuen que estan més a prop de l'interval de confiança encara que seguexen hovent hi algunes que són significatives.

Ajustar el model

Ara mateix tenim a aquest a model, més concretament un model ARIMA. Per saber quins parametres afegir ens fixarem en les gràfiques ACF i PACF. De l'ACF indicarem la q i la Q i de PACF la p i P, a més, com hem fet diferenciació d'ordre 1 i 12 la d i D serien 1.

Model 1

```
diabetes_arima <- arima(Diabetes,
                        order = c(0,1,1),
                        seasonal = list(order = c(0,1,1),
                                        period = 12))
#Mfitted=fitted(
retVec = round(dic(diabetes_arima)$aicVec[seq(1,by=2,length.out=10)],3)
retVec

## ar1 ar2 ar3 ma1 ma2 ma3
## 1.76 0.67 1.56 2.26 3.27 2.82

retVec2
## ar1 ar2 ma1 ma2 sma1 sma2
## FALSE FALSE TRUE TRUE TRUE TRUE
```

Després d'ajustar el model ens mirem si les dades i els parametres són significatius o no hi ha cap, cls anem ajustant fins que ho siguin. Per saber si són significatius calculem el valor absolut com com el valor entre l'error estàndard, si és més gran que 2 aleshores és significatiu. Com podem veure a l'ar1 ar2 ma1 FALSE així que hauriem de canviar el parametre corresponent, agafarem el que tinga el numero més alt i el determinarem així.

Model 2

```
diabetes_arima2 <- arima(Diabetes,
                         order = c(0,1,1),
                         seasonal = list(order = c(0,1,1),
                                         period = 12))
#Mfitted=fitted(
retVec = round(dic(diabetes_arima2)$aicVec[seq(1,by=2,length.out=10)],3)
retVec

## ar1 ar2 ma1 ma2 sma1 sma2
## 1.81 0.57 1.25 3.23 2.82

retVec2
## ar1 ar2 ma1 ma2 sma1 sma2
## TRUE TRUE TRUE TRUE TRUE TRUE
```

Com podem veure tot els parametres són significatius així que aquest serà el model definitiu.

```
#Mfitted=fitted(
MSE(diabetes_arima2)
```

```
## [1] 138.5054
```

```
MSE(diabetes_arima2)  #Mirem aquest amb boxcox millor
```

```
## [1] 632.5582
```

```
mod_def <- diabetes_arima2
```

Validació

Una vegada tenim el model definitiu provarem amb la validació del model i de les seves dades, analitzarem l'homocedasticitat, la normalitat i la independència.

Homocedasticitat

```
resid0 = mod_def$residuals
par(mar=c(3,3), mar=c(3,3,3,3))
plot(resid0, main = "Residuals")
abline(h =c(0, -1*sqrt(var(resid0)), sqrt(var(resid0))), lty = c(1,2,2), col=c(1,2,2))
scatter.smooth(sqrt(abs(resid0)),
               main = "Square Root of Absolute residuals",
               type = 'p',pch=19)
```


Com podem veure la variància és més o menys constant si no tenim en compte el primer any, que és aquesta bola conjunta de dades que està a la cantonada de forma a l'esquerra. Una manera de poder solucionar aquest problema fa/ó i ripartament seria eliminant tot el primer any.

Normalitat

```
par(mar=c(3,3), mar=c(3,3,3,3))
qqnorm(resid0)
qqline(resid0,col=2,lwd=2)
hist(resid0, prob=T, nclass=15, breaks=7)
curve(dnorm(x, mean = mean(resid0), sd = sd(resid0)), col=2, add=T)
```


Com podem veure les dades als extrems tant de la pista estan molt separades de la recta, el qual és un problema gros, ja que ens indica que les dades no seguexen una distribució normal.

Independència

```
tsdisplay(mod_def$ resid, lag.max = 40)
```


On ens pot veure observem a les dades són independents o no és a l'últim gràfic. La línia discontinua blava és la línia del p-valor 0.05, si els punts estan per sota d'aquesta línia llavors no tenge la hipòtesi 0, H0, i per tant les dades no són independents.

Després d'analitzar aspectes gràfics de validació podem anar per fer-ho per les nostres dades no són validees, ja que no són independents, normals, ni tenen homocedasticitat. Encara i així podem seguir-hi per la predicció, no obstant això, com les dades no són validees no podem assegurar que la predicció siga correcta.

Predicció

```
# Forecast for the next 12 time periods
pred0 <- predict(mod_def$ fit, n.ahead=36) #n per 3 anys
mi_rmpf <- pred0$pred
mi_rmse <- pred0$se

# Intervals de rmpf
ls_rmpf <- mi_rmpf + 1.96 * mi_rmse # limit inferior rmp
ls_rmpf <- mi_rmpf + 1.96 * mi_rmse # limit superior rmp

# Bucle superior
ls <- ts(ls(ls_rmpf), start = 1995, freq=12)
li <- ts(li(ls_rmpf), start = 1995, freq=12)
ls <- ts(ls(ls_rmpf), start = 1995, freq=12)

plot(
plot(Diabetes,
     xlim=c(1995,2010),
     ylim=c(-0.5,1.5), xaxs="blank",ylab="Diab",type="both",
     xlim = c(1995,2011))
```


En conclusió, aquesta serie la predicció de les vendes de motocultivadores ambdalabdora a Australia des anys en el futur, és el 2009 i 2010. Però, com ja hem explicat abans, no podem assegurar que aquesta predicció siga correcta, ja que el model model no és vàlid.