

Sèries Temporals

2024-11-02


Introducció

L'objectiu d'aquesta anàlisi és descriure els patrons de la sèrie temporal, estimar i validar els paràmetres i fer una predicció dels valors futurs.

La base de dades és una diferent de la que hem estat treballant fins ara, ja que no tenim cap variable temporal. La base de dades que utilitzem és una integració en el motes R de la venda de drogues anti-diabètiques, com és la insulina, a Austràlia des de 1992 fins a 2008. El conjunt de dades consta de dos columnes una de les dates, que són mensuals, i una altra de les vendes, hi ha un total de 204 files.

Creem l'objecte 'ts'


```
Diabetes <- ts(a10, start = 1992, frequency = 12)
plot(Diabetes)
```



Si analitzem la gràfica de les dades de la nostra sèrie temporal podem veure que no és estacionària, per tant, hem de fer alguns canvis perquè ho sigui. Primer de tot, hem de veure si la variància és constant, que no ho és, així que apliquem el logarítmic. La transformació logarítmica és la més directa per poder deixar la variància constant.

Transformació logarítmica

```
lndiabetes <- log(Diabetes)
plot(lndiabetes)
```



Dibuixem les components de la sèrie


```
plot(decompose(lndiabetes))
```



Ara la variància és constant, però com podem veure hi ha un patró estacional. És per això que fem de fer una diferenciació d'ordre 12, per treure l'estacionalitat. És d'ordre 12 perquè les nostres dades són mensuals i llavors la freqüència de les dades és de 12.

ACF i PACF


```
par(mfrow=c(1,2))
acf(lndiabetes, ylim=c(-1,1), lag.max = 40)
pacf(lndiabetes, ylim=c(-1,1), lag.max = 40)
```



També es pot veure que les dades no són estacionàries en l'ACF, si l'ACF es redueix gradualment des de l'1 fins al 0 vol dir que no és estacionària.

Diferenciació d'ordre 12


```
par(mfrow=c(1,1))
d12lndiabetes <- diff(lndiabetes, lag=12)
plot(d12lndiabetes)
```



Per últim, mirem si la mitjana és constant o no, com podem veure no ho és. Per tant fem una altra diferenciació per fer-la constant, i amb això hauréem acabat de preparar les nostres dades per començar a preparar el model.

ACF i PACF


```
par(mfrow=c(1,2))
acf(d12lndiabetes, ylim = c(-1,1), lag.max = 40)
pacf(d12lndiabetes, ylim = c(-1,1), lag.max = 40)
```




En l'ACF i PACF ens podem fixar quins coeficients són significatius, si sobrepassen les línies són significatius. Volem que hi hagi la quantitat més gran possible de línies que estiguin dins de l'interval de confiança, que és l'espai entre les dues discontinues blaves.

Diferenciació d'ordre 1

```
d1d12lndiabetes <- diff(d12lndiabetes)
plot(d1d12lndiabetes)
```



```
par(mfrow=c(1,2))
plot(Diabetes)
```



Finalment, hem acabat d'arreglar el nostre model, l'ha passat de ser no estacionari a estacionari. Amb aquests dos gràfics podem veure els canvis que li hem fet, ara te variància i mitjana constant i no té patrons estacionals.

ACF i PACF

```
par(mfrow=c(1,2))
acf(d1d12lndiabetes, ylim=c(-1,1), lag.max = 40) #es mira q i q
pacf(d1d12lndiabetes, ylim=c(-1,1), lag.max = 40) #es mira p i p
```



Si ens fixem ara tenim en el PACF línies que estan més a prop de l'interval de confiança encara que segueixen havent-hi algunes que són significatives.

Ajustar el model

Ara començarem a ajustar el model, més concretament un model ARIMA. Per saber quins paràmetres afegir ens fixarem en les gràfiques ACF i PACF. De l'ACF extreurem la q i la Q i del PACF la p i P, a més, com hem fet diferenciació d'ordre 1 i 12 la d i D seran 1.

Model 1

```
diabetes.arima1 <- arima(lndiabetes,
  order = c(1,1,1),
  seasonal = list(order = c(0,1,3),
    period = 12))
```

```
##Significatius
ratios <- round(abs(diabetes.arima1$coef/sqrt(diag(diabetes.arima1$var.coeff))),2)
ratios
```

```
## ar1 ar2 ma1 sma1 sma2 sma3
## 1.16 8.11 5.38 7.28 3.23 2.82
```

```
ratios2
```

```
## ar1 ar2 ma1 sma1 sma2 sma3
## FALSE FALSE TRUE TRUE TRUE TRUE
```

Després de crear el model hem de mirar si els paràmetres són significatius i si no ho són, els anem ajustant fins que ho siguin. Per saber si són significatius calculem els ràtios com podem veure a sobre, hem d'aconseguir que tots el ràtios siguin majors a 2, és a dir que tots siguin TRUE. Com podem veure ar1 i ar2 són FALSE així que hauréem de canviar el paràmetre corresponent, agafarem el que tingui el número més alt i el disminuïrem en 1.

Model 2

```
diabetes.arima2 <- arima(lndiabetes,
  order = c(1,1,1),
  seasonal = list(order = c(0,1,3),
    period = 12))
```

```
##Significatius
ratios <- round(abs(diabetes.arima2$coef/sqrt(diag(diabetes.arima2$var.coeff))),2)
ratios
```

```
## ar1 ma1 sma1 sma2 sma3
## 2.81 9.31 7.29 3.23 2.82
```

```
ratios2
```

```
## ar1 ma1 sma1 sma2 sma3
## TRUE TRUE TRUE TRUE TRUE TRUE
```

Com podem veure tots els paràmetres són significatius així que aquest serà el model definitiu.

```
##Model definitiu -----
fit(diabetes.arima2)
```

```
## [1] -510.3454
```

```
AIC(diabetes.arima2) #AIC quant més baix millor
```

```
## [1] -512.3342
```

```
mod_deff <- diabetes.arima2
```

Validació

Una vegada tenim el model definitiu prosseguim amb la validació del model i de les dades, analitzarem l'homocedasticitat, la normalitat i la independència.

Homocedasticitat


```
resid <- mod_deff$residuals
par(mfrow=c(1,2), mar=c(5,3,3,3))
plot(resid, main="Residuals")
abline(h = c(0, -1.96*sd(resid), 1.96*sd(resid)), lty = c(1,3,3), col=c(1,4,4))
scatter.smooth(sqrt(abs(resid)),
  main="Square Root of Absolute Residuals",
  lpar = list(col=2))
```



Com podem veure la variància és més o menys constant si no tenim en compte el primer any, que és aquesta bola conjunta de dades que està a la part superior de baix a l'esquerra. Una manera de poder solucionar aquest problema fàcil i ràpidament seria eliminant tot el primer any.

Normalitat

```
par(mfrow=c(1,2), mar=c(5,3,3,3))
qqnorm(resid)
qqline(resid,col=2,lwd=2)
hist(resid,breaks = 10, freq=F)
curve(dnorm(x, mean = mean(resid), sd = sd(resid)), col=2, add=T)
```



Com podem veure les dades als extrems del q-q plot estan molt separades de la recta, el qual és un problema greu, ja que ens indica que les dades no segueixen una distribució normal.

Independència

```
tsdiag(mod_deff, gcf.lag = 40)
```


On es pot veure clarament si les dades són independents o no és a l'últim gràfic. La línia discontinua blava és la línia del p-value 0.05, si els punts estan per sota d'aquesta línia llavors es nega la hipòtesi 0. H0, i per tant les dades no són independents.

Després d'analitzar aquesta gràfica de validació podem donar per fet que les nostres dades no són vàlides, ja que no són independents, normals ni tenen homocedasticitat. Encara i així podem seguir i fer la predicció, no obstant això, com les dades no són vàlides no podem assegurar que la predicció sigui correcta.

Predicció

```
## Calcul de les prediccions i de l'error estandard
pred <- predict(mod_deff, n.ahead=14) #14 es 2 anys
pr_logd <- pred$pred
se_logd <- pred$se
```

```
## Intervals de logs
li_logd <- pr_logd - 1.96 * se_logd # limit inferior log
ls_logd <- pr_logd + 1.96 * se_logd # limit superior log
```

```
## Desfer logarítmic
li <- ts(exp(li_logd), start = 2009, freq=12)
pr <- ts(exp(pr_logd), start = 2009, freq=12)
ls <- ts(exp(ls_logd), start = 2009, freq=12)
```

```
## Gràfic
par(mfrow=c(1,1))
ts.plot(Diabetes,
  li, ls, pr,
  lty = c(1,2,2,1), col=c("black","blue","blue","red"),
  xlim = c(1992,2011))
```


En conclusió, aquesta seria la predicció de les vendes de medicaments anti-diabètics a Austràlia dos anys en el futur, és a dir 2009 i 2010. Però, com ja hem explicat abans, no podem assegurar que aquesta predicció sigui correcta, ja que el nostre model no és vàlid.